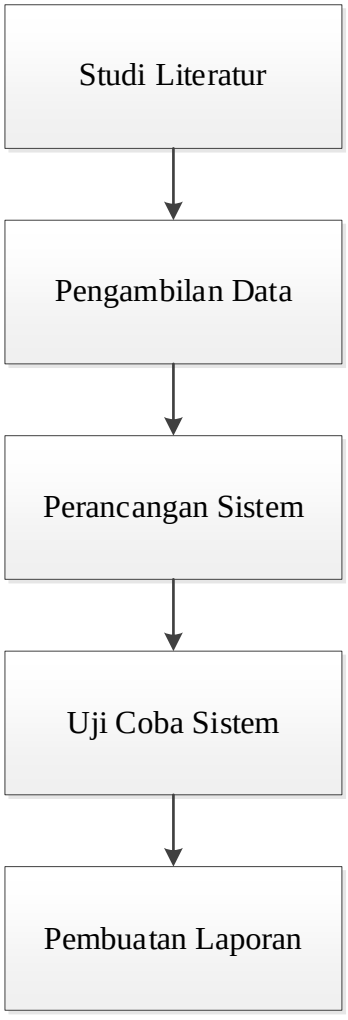
BAB III METODE PENELITIAN

3.1 Jenis Penelitian

Jenis penelitian ini adalah penelitian kuantitatif yang menggunakan metode analisis dan eksperimen berdasarkan ruang lingkup masalah yang diangkat. Masalah yang diangkat diselesaikan menggunakan salah satu teknik komputasi yaitu *machine learning*.

3.2 Tahapan Penelitian

Pada penelitian ini, Langkah-langkah yang dilakukan sebagai berikut :



Gambar 3. 1 Langkah Penelitian

a. Studi literatur adalah tahapan dimana peneliti mencari referensi terkait penelitian yang sedang disusun. Tahap ini termasuk identifikasi masalah, menentukan metode yang digunakan serta mencari dataset harga saham
b. Pengumpulan data dan perancangan sistem adalah tahapan yang dilakukan dalam waktu yang sama. Data dikumpulkan melalui API *yahoo finance* kemudian dilakukan *pre-processing* pada masing-masing data. Data sentiment akan melalui beberapa tahap yaitu *number removal, stemming porter, stop words, punctuation removal, tokenize, transform to lowercase, spell correction* dan *lemmatization*. Data sentiment kemudian diproses menggunakan algoritma *lexicon based learning* yang outputnya adalah skor sentiment. Skor sentiment, data fundamental dan data teknikal akan menjadi input pada algoritma LSTM dan akan dilakukan evaluasi.
c. Melakukan evaluasi dan menganalisa keakuratan sistem yang dibuat berdasarkan *performance evaluation metrics* yaitu MSE, RMSE dan MAE
d. Pembuatan laporan dilakukan dengan menulis laporan akhir studi dan bahan untuk publikasi.

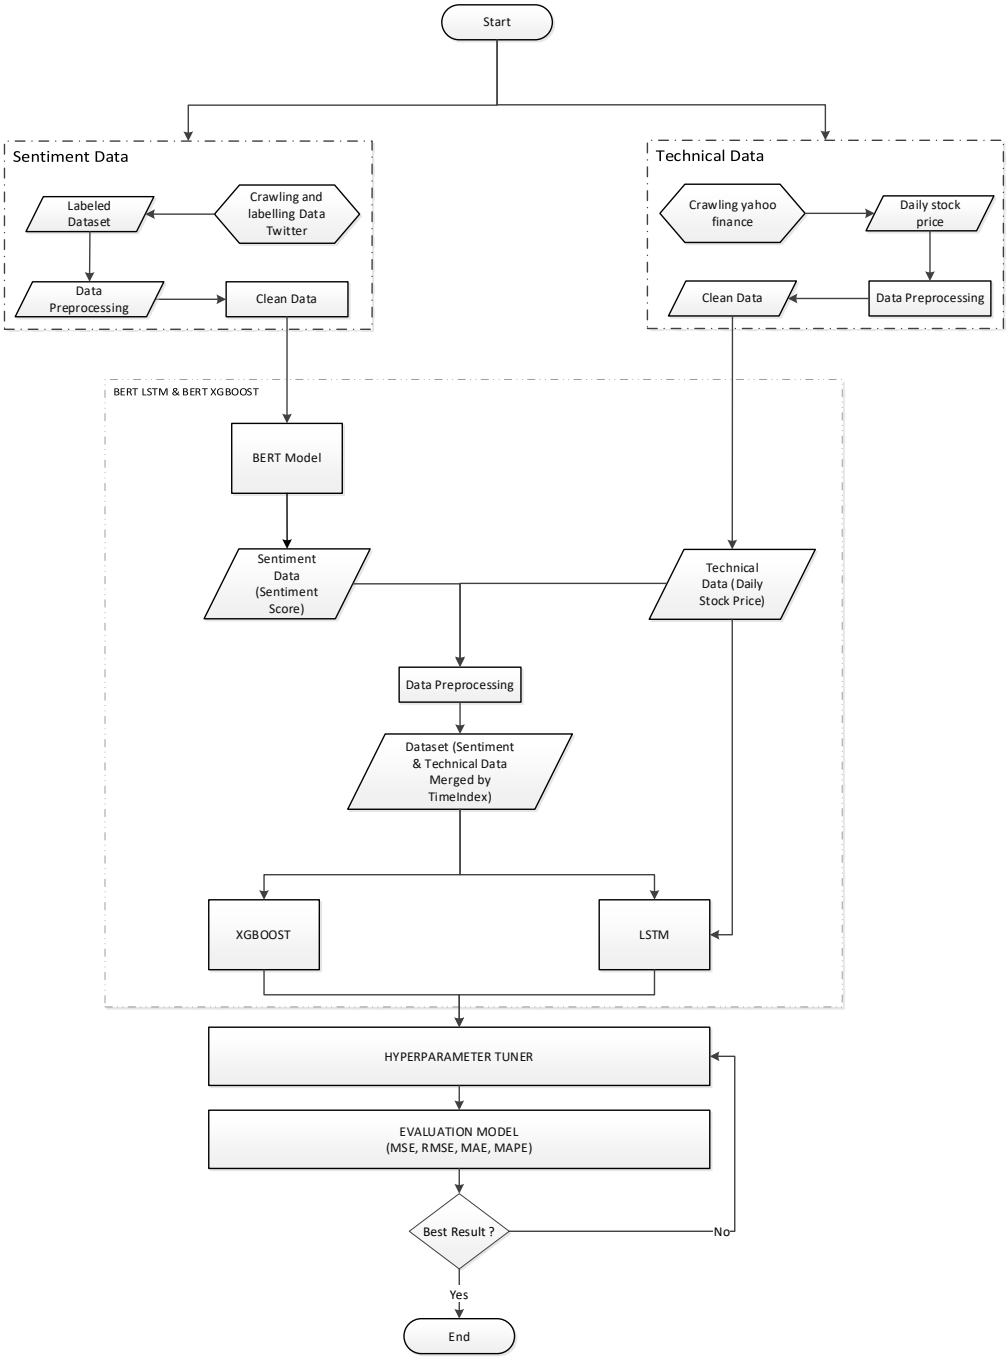
3.3 Sumber Data

Dataset yang digunakan terbagi dua jenis yaitu dataset analisis sentiment dan dataset analisis teknikal :

a. Dataset analisis sentiment berjumlah 9.738 data mengenai saham BBRI dari tanggal 06/07/2020 hingga 30/12/2022 yang terdiri dari dua fitur yaitu tweet dan date. Dataset ini di split dengan ratio 70%-30% dengan jumlah data train sebanyak 6.892 dan jumlah data test sebanyak 2.846 dan digunakan untuk melatih dan mengevaluasi model BERT.
b. Dataset analisis teknikal diperoleh dari scrapping Yahoo Finance. Dataset berupa harga saham harian BBRI dari tanggal 22/07/2020 hingga 30/12/2022 berjumlah 891 data dengan timeframe 1 day. Dataset terdiri dari beberapa fitur *yaitu open price, close price, highest price, lowest price, RSI, MA, Stochastic oscillator dan volume.*

3.4 Rancangan Sistem

Pada penelitian ini, ada beberapa tahapan yang dilakukan untuk prediksi harga saham menggunakan analisis teknikal dan skor sentiment. Tahapan-tahapan tersebut ditunjukkan pada *flowchart* dibawah:



Gambar 3. 2 Rancangan Sistem

Pada *flowchart* diatas menjelaskan proses prediksi harga saham. Tahap awal adalah proses pengambilan data analisis sentiment dari Twitter dan analisis teknikal dari *yahoo finance*. Setelah data analisis teknikal dan analisis sentiment telah ada, selanjutnya dilakukan tahap *pre-processing* yang sesuai pada masing-masing jenis data dan dilanjutkan pada proses pengembangan model. Data analisis sentiment diproses menggunakan algoritma BERT modifikasi dan menghasilkan output berupa skor sentiment yang akan digabung dengan data teknikal. Data gabungan tersebut kemudian digunakan untuk melatih model XGBoost dan LSTM. Model BERT-XGBoost dan BERT-LSTM dilatih menggunakan gabungan kedua jenis data sedangkan model LSTM hanya menggunakan data teknikal saja. Ketiga model yaitu BERT-XGBoost, BERT-LSTM dan LSTM akan dievaluasi menggunakan MAE, MAPE, MSE dan RMSE. Adapun pembahasan mengenai pengumpulan dataset, *pre-processing* dan pencaharian *hyperparameter* dijelaskan sebagai berikut.

a. Pengumpulan Dataset

1. Dataset Analisis sentiment

Dataset analisis sentiment diperoleh dari proses scrapping Twitter. Scrapping twitter dilakukan menggunakan library snscrape. Variabel query berisi kondisi pengambilan data pada twitter dimana tweet yang diambil harus memenuhi syarat yaitu memiliki hashtag #BBRI, tidak memuat link dan bukan merupakan balasan tweet. Jumlah data yang diambil dibatasi hingga 10.000 data. Data yang diambil berisi 2 fitur yaitu Date dan tweet. Selanjutnya data yang diperoleh disimpan dalam array yang kosong hingga mencapai limit. Array tersebut disimpan dalam data frame lalu disimpan menjadi file tweet.csv.

2. Dataset Analisis teknikal

Proses pengambilan data analisis teknikal menggunakan library yahoo finance. Dimulai dengan data harga saham BRI di scrapping mulai dari tanggal 22/07/2020 hingga 30/2/2022. Selanjutnya function asfreq(‘D’) digunakan pada dataset untuk memperoleh data dengan frekuensi harian. Misalnya, jika df awalnya memiliki indeks dengan tanggal-tanggal tertentu dan beberapa tanggal tidak muncul dalam indeks karena data hilang pada tanggal-tanggal itu, asfreq('D') akan menambahkan baris dengan tanggal-tanggal yang

hilang dan mengisi nilai-nilai yang hilang dengan NaN sehingga tidak ada data date yang hilang atau terlangkahi.

b. *Pre-processing*

Pre-processing data dilakukan untuk membersihkan, mengubah dan menyesuaikan data agar sesuai dengan apa yang kita butuhkan. Hal ini juga dapat meningkatkan akurasi prediksi model. *pre-processing* data yang dilakukan sebagai berikut :

1. *Pre-processing* Analisis sentiment

Pre-processing analisis sentiment dilakukan dalam beberapa tahap yaitu strip emoji, strip entities, clean hashtags, filter chars dan remove multi spaces.

a) Strip emoji

Strip emoji adalah tahap *pre-processing* yang berfungsi untuk menghapus emoji. Penghapusan emoji menggunakan sebuah *function* atau class yang dimuat dalam variabel text.

b) Strip entities

Strip entities berfungsi untuk menghapus tautan, mention, dan karakter non-ASCII dari variabel text. Function atau *class* ini membersihkan teks dari elemen-elemen yang tidak relevan.

c) Clean hashtags

Function atau class ini berfungsi untuk menghapus hashtag dari variabel tweet. Mulanya function ini menghapus hashtag diakhir kalimat kemudian menghapus simbol # dari variabel tweet di tengah kalimat. Hal ini memungkinkan untuk mempertahankan konteks kata-kata yang terhubung dengan hashtag tanpa karakter khusus.

d) Filter chars\

Function atau class ini memfilter karakter khusus seperti $ dan ‘&’ dari data. Karakter khusus ini dapat mengganggu dalam analisis sentiment, terutama jika karakter tersebut tidak terikat pada konteks tertentu.

e) Remove multi spaces

Function atau *class* ini digunakan untuk menghapus spasi ganda dari teks. Hal ini dilakukan agar teks terlihat rapi dan terstruktur.

Keseluruhan function kemudian digunakan untuk memproses dataset yang dimuat dalam array *texts_new*. Selanjutnya data array tersebut disimpan dalam data frame *df*. Secara keseluruhan, kodingan diatas mengimplementasikan serangkaian langkah dalam tahap *pre-processing* analisis sentiment agar dataset berupa teks tersebut bersih dari elemen-elemen yang tidak relevan atau mengganggu sehingga siap digunakan untuk pembuatan model.

2. *Pre-processing* Analisis teknikal

Pre-processing analisis teknikal dimulai dari tahap penggabungan data teknikal dan skor sentiment, menghapus baris kosong dan normalisasi data.

a) Penggabungan data teknikal dan skor sentiment

Gabungan data teknikal dan skor sentiment digunakan untuk melatih model BERT-LSTM dan BERT-XGBoost. Penelitian ini memerlukan satu skor sentiment per hari sebagai representasi pasar pada hari itu, sehingga dilakukan proses mencari rata-rata. Data skor sentiment yang memiliki kesamaan tanggal akan dijumlahkan dan dibagi dengan jumlahnya sendiri sesuai rumus berikut :

$$x = \frac{x1^{t1} + x2^{t1} + x3^{t1} + xn^{t1}}{xn}$$

Proses mencari rata-rata diatas, dilakukan pada semua data skor sentiment waktu yang berbeda $xn^{t1}, xn^{t2}, xn^{t3}, xn^{tn}$. Setelah proses selesai maka data skor sentiment terlihat seperti berikut.

Tabel 3. 1 Contoh data Skor sentiment setelah penggabungan

Date	Skor Sentiment
2020-07-22	0.310727
2020-07-23	0.046449
2020-07-24	0.514676
2020-07-25	0.517581
2020-07-26	0.998282

Selanjutnya mempersiapkan data teknikal. Data teknikal yaitu data saham BRI di scrapping dari yahoo finance mulai dari tanggal 22-07-2020 sampai 30-12-2022

dan di sortir berdasarkan hari. Beberapa data hasil scrapping dapat dilihat pada tabel dibawah ini.

Tabel 3. 2 Contoh data hasil scraping

Date	Open	High	Low	Close	Adj Close	Volume
22/07/2020	2.872.677.734	2.881.768.311	2.809.042.480	2.818.133.057	2.363.973.145	190916547.0
23/07/2020	2.836.314.697	2.872.677.734	2.818.133.057	2.854.496.094	2.394.476.074	162646279.0
24/07/2020	2.845.405.518	2.854.496.094	2.809.042.480	2.809.042.480	2.356.347.656	104287961.0
25/07/2020	NaN	NaN	NaN	NaN	NaN	NaN
26/07/2020	NaN	NaN	NaN	NaN	NaN	NaN

Berdasarkan tabel 3.2 diatas, terlihat ada data teknikal yang memiliki nilai NaN atau kosong. Data-data yang kosong tersebut adalah data pada hari sabtu dan minggu dimana bursa saham tutup atau tidak beroperasi. Selanjutnya, data NaN atau kosong tersebut ditangani atau diisi menggunakan teknik *smoothing* yaitu menggunakan nilai rata-rata harga saham 4 hari sebelumnya. Hasil proses nya dapat dilihat pada gambar tabel ini.

Tabel 3. 3 Contoh data teknikal setelah *smoothing*

Date	Open	High	Low	Close	Adj Close	Volume
22/07/2020	2.872.677.734	2.881.768.311	2.809.042.480	2.818.133.057	2.363.973.145	190916547.0
23/07/2020	2.854.496.216	2.877.223.022	2.813.587.769	2.836.314.575	2.379.224.609	176781413.0
24/07/2020	2.851.465.983	2.869.647.380	2.812.072.673	2.827.223.877	2.371.598.958	152616929.0
25/07/2020	2.851.465.983	2.869.647.380	2.812.072.673	2.827.223.877	2.371.598.958	152616929.0
26/07/2020	2.840.860.107	2.863.586.914	2.813.587.769	2.831.769.287	2.375.411.865	133467120.0

Kemudian dilakukan penggabungan data teknikal dengan data skor sentiment berdasarkan waktu. Penggabungan ini diharapkan dapat memberikan insight pada model mengenai sentiment pasar setiap hari. Dataset juga ditambahkan dengan beberapa indikator teknikal seperti RSI, MA5, MA10, MA20 dan Oscilattor. Hasil proses ini dapat dilihat pada tabel 3.4 dibawah ini.

Tabel 3. 4 Contoh dataset setelah penggabungan

Date	Open	High	Low	Close	Adj Close	Volume	SkorSentiment	RSI	MA_5	MA_10	MA_20	S_Osci
22/07/2020	2.872.677.734	2.881.768.311	2.809.042.480	2.818.133.057	2.363.973.145	190.916.500.000.000	0.310727	35.846.908	2.828.132.935	2.839.875.181	2.822.867.904	30.952.363

23/07/2020	2.863.586.975	2.879.495.667	2.811.315.125	2.827.223.816	2.371.598.877	183.849.000.000.000	0.178588	35.846.908	2.828.132.935	2.839.875.181	2.822.867.904	30.952.363
24/07/2020	2.859.546.644	2.876.212.904	2.811.567.641	2.827.223.836	2.371.598.904	173.438.300.000.000	0.290617	35.846.908	2.828.132.935	2.839.875.181	2.822.867.904	30.952.363
25/07/2020	2.857.526.479	2.874.571.523	2.811.693.899	2.827.223.846	2.371.598.918	168.233.000.000.000	0.290617	35.846.908	2.828.132.935	2.839.875.181	2.822.867.904	30.952.363
26/07/2020	2.849.572.072	2.870.026.174	2.812.830.221	2.830.632.904	2.374.458.598	153.870.600.000.000	0.359568	35.846.908	2.828.132.935	2.839.875.181	2.822.867.904	30.952.363

b) Normalisasi data

Sebelum data digunakan untuk pelatihan model, terlebih dahulu dilakukan normalisasi data. Hal ini bertujuan agar data memiliki skala nilai yang sama sehingga saat pelatihan model, tidak ada fitur yang lebih dominan. Normalisasi data dilakukan menggunakan library MinMaxScaler dari SKlearnpreprocessing. Hasil proses ini dapat dilihat pada tabel 3.5 dibawah ini.

Tabel 3. 5 Contoh dataset setelah normalisasi

Date	Open	High	Low	Close	Adj Close	Volume	SkorSentiment	RSI	MA_5	MA_10	MA_20	S_Osci
2020-07-22	0.031593	0.020848	0.039428	0.026858	0.023439	0.262161	0.310480	0.26242	0.020252	0.014975	0.0	0.3172
2020-07-23	0.027322	0.019783	0.040475	0.030989	0.027045	0.248093	0.178226	0.26242	0.020252	0.014975	0.0	0.3172
2020-07-24	0.025423	0.018246	0.040591	0.030989	0.027045	0.227371	0.290353	0.26242	0.020252	0.014975	0.0	0.3172
2020-07-25	0.024474	0.017477	0.040650	0.030989	0.027045	0.217009	0.290353	0.26242	0.020252	0.014975	0.0	0.3172
2020-07-26	0.020736	0.015348	0.041173	0.032539	0.028397	0.188421	0.359365	0.26242	0.020252	0.014975	0.0	0.3172

c. Pencarian *Hyperparameter*

Hyperparameter adalah salah satu proses dalam tahapan implementasi Deep Learning dimana untuk setiap parameter-parameter yang tidak dapat dipelajari oleh model (*Hyperparameter*) disesuaikan atau disetel secara eksternal sehingga dapat meningkatkan kinerja model dan membantu model belajar dari data [23]. Tahap ini merupakan proses mengatur skenario parameter agar menghasilkan parameter yang tepat agar algoritme dapat mempelajari pola-pola yang terdapat dalam data dengan baik [24].

1. BERT

Proses pencarian hyperparameter algoritma BERT fokus pada pencarian model pretrained yang tepat. Model pretrained algoritma BERT bersifat open source dan dapat diperoleh dari website hunggingface.co. Model pretrained tersebut harus dapat digunakan untuk klasifikasi analisis sentiment dalam bahasa Indonesia. Adapun beberapa model pretrained yang memungkinkan untuk digunakan sebagai berikut :

a) *Indobert-base-p1 & Indobert-base-p2* adalah varian dari model IndoBERT yang menggunakan BERT-Base sebagai *baseline*. Varian ini dikembangkan oleh *indobenchmark* dan dikhususkan digunakan untuk analisis sentiment bahasa Indonesia. Pelatihan model ini menggunakan dataset *Indo4B* dengan total ukuran data sebesar 23.43 GB berisi teks.

b) *Indobert-base-uncased* adalah model yang dikembangkan oleh *indolem* dengan menggunakan BERT-Base sebagai *baseline*. Model dilatih menggunakan 220 Juta kata yang terdiri dari Wikipedia Indonesia 74 Juta kata; artikel berita seperti Kompas, Tempo dan Liputan 6 sebanyak 55 Juta kata; dan Web Korpus Indonesia sebanyak 90 Juta kata.

c) *Indobert-base- classification* adalah versi pengembangan dari *indobert-base-p1* yang menggunakan dataset *indonlu* dalam proses pelatihan. Hasil evaluasi dari versi pengembangan ini adalah loss: 0.3707; Accuracy: 0.9397; F1:0.9393.

Adapun hasil pencaharian *hyperparameter* algoritma BERT untuk analisis sentiment pada ini sebagai berikut :

Tabel 3. 6 Hyperparameter Tuning BERT

No	Model *Pretrained*	*Epoch*	***Evaluasi Model Pretrained***		
			Training Loss	***Validation Loss***	***Validation Accuracy (%)***
1	*Indobert-base-p1*	*10*	0.013	0.37	92.55
2	*Indobert-base-p2*	*10*	0.020	0.29	92.73
3	*Indobert-base-uncased*	*10*	0.095	0.22	92.27
4	*Indobert-base-classification*	*10*	0.014	0.41	91.04

Berdasarkan Tabel diatas, *Training Loss* digunakan untuk mengetahui seberapa baik model dalam melakukan prediksi saat *training*. Semakin rendah *training loss* maka semakin baik model. Sedangkan, *validation loss* digunakan untuk mengetahui seberapa baik model saat melakukan prediksi pada data yang tidak digunakan pada saat *training*. Jika *training loss* menurun sedangkan *validation loss* meningkat maka biasanya terjadi *overfitting* pada model. Hasil pencaharian diatas, menunjukkan bahwa *indobert-base-p2* memperoleh *validation accuracy 92.73 %* yang lebih tinggi dibandingkan *model pretrained* yang lain selain itu GAP antara *training loss* dan *validation loss* juga lebih rendah sehingga model BERT *pretrained* yang akan digunakan pada penelitian ini adalah *indobert-base-p2.*

2. LSTM

Proses pencarian *hyperparameter* pada algoritma LSTM menggunakan teknik *random search* dari kumpulan angka *random* yang telah disiapkan. Adapun beberapa *hyperparameter* yang dianggap dapat mempengaruhi kinerja model LSTM secara signifikan sebagai berikut [24] :

a) Neuron merupakan unit yang paling dasar pada jaringan LSTM. Neuron LSTM memiliki struktur yang kompleks yang terdiri dari beberapa komponen utama seperti input gate, forget gate, output gate dan memory cell. Struktur tersebut

membuat LSTM dapat mempertahankan informasi dalam jangka waktu yang lama dan mengatasi masalah gradient yang menghilang.

b) Epoch adalah proses pelatihan suatu model yang menggunakan seluruh set data untuk menyesuaikan bobot jaringan saraf. Epoch menunjukkan berapa kali dataset diberikan ke model.

c) Batch Size adalah jumlah sampel data dari set data yang diberikan ke model pada setiap iterasi atau langkah penelitian. Hal ini berarti set data dibagi menjadi batch kecil dan model diperbaharui setiap batch tersebut.

d) Jumlah Layer merupakan salah satu dari beberapa faktor yang dapat dioptimalkan dalam desain model. Jumlah layer yang biasa digunakan pada LSTM bervariasi tergantung dari kompleksitas model yang dibuat.

Berikut hasil pencaharian *hyperparameter* algoritma LSTM yang digunakan untuk analisis teknikal :

Tabel 3. 7 Hyperparameter Tuning LSTM dan BERT-LSTM

No	***Model***	***Number of neurons***	***Epoch***	***Batch Size***	***Evaluation***	
					Validation MSE	***Validation MAE***
1	LSTM	5	20	32	0.12	0.09
		10	20	32	0.15	0.10
		15	20	32	0.10	0.08
2	BERT-LSTM	5	20	32	0.62	0.21
		10	20	32	0.45	0.18
		15	20	32	0.19	0.11

Pencaharian *hyperparameter* LSTM fokus pada mencari nilai *number of neurons* yang optimal. Berdasarkan Tabel diatas, model LSTM dan BERT-LSTM sama-sama memperoleh nilai validation MSE dan MAE terkecil yaitu 0.10, 0.08 dan 0.19, 0.11 ketika nilai number of neurons 15, Sehingga *hyperparameter* yang digunakan pada model LSTM dan BERT-LSTM adalah *number of neurons* 15, *epoch* 20 dan *batch size* 32.

3. XGBoost

Pencarian *hyperparameter* model XGBoost menggunakan teknik *grid search*. *Grid search* adalah teknik pencarian *hyperparameter* yang mengeksplorasi parameter dengan nilai-nilai yang telah disiapkan sebelumnya secara sistematis. Berdasarkan hasil yang diperoleh oleh peneliti saat pra-penelitian terdapat beberapa *hyperparameter* yang memiliki pengaruh besar terhadap akurasi model yaitu *max depth, n_estimators, lags* dan *learning rate*.

a) *Maxdepth* adalah jumlah tingkat atau cabang maksimum yang dapat digunakan pada *decision tree* selama proses *training.* Semakin besar nilai *Maxdepth* maka semakin kompleks model nya. Akan tetapi, juga dapat membuat model *overfitting* sehingga menentukan nilai *Maxdepth* yang tepat adalah hal yang penting.
b) *n_estimators* adalah jumlah *decision tree* yang digunakan selama proses training. *Maxdept*h mengatur kedalaman *decision tree* (secara vertikal) sedangkan *estimators* mengatur jumlah *decision tree* (secara horizontal). Jumlah *estimators* dapat meningkatkan akurasi model, semakin banyak jumlah *estimators* maka semakin kompleks model. Akan tetapi, terdapat kondisi dimana penambahan jumlah *decision tree* tidak lagi memberikan peningkatan signifikan terhadap akurasi model dan hanya akan meningkatkan waktu pelatihan tanpa manfaat.
c) *lags* adalah kondisi dimana model memanfaatkan data sebelumnya untuk digunakan sebagai fitur untuk memprediksi nilai di masa depan. Misalnya dalam penelitian ini, model akan menggunakan data harga saham harian beberapa hari sebelumnya untuk memprediksi harga saham harian di masa depan. Hal ini membuat model dapat menangkap pola atau tren dalam data seiring waktu.
d) *learning rate* menentukan seberapa besar bobot (*weight*) dari setiap fitur akan diperbaharui setiap iterasi. Semakin besar nilai *learning rate* maka kemungkinan model memperoleh nilai konvergensi lebih cepat tetapi juga beresiko melompati minimum global (*overshooting*) atau nilai yang dihasilkan model melewati nilai yang dianggap wajar.

   Pencarian hyperparameter pada algoritma XGBoost dilakukan menggunakan teknik pencarian grid search Adapun rincian konfigurasi pencarian hyperparameter yang dilakukan dijelaskan pada tabel berikut :

Tabel 3. 8 Konfigurasi *Hyperparameter* tuning XGBoost

No	Parameter	Value
1	Model	XGBoost Regressor
2	Maxdepth	[150,200,300,400,500]
3	n_estimators	[80,100,150,200]
4	Learning rate	[0.1,0.2]
5	Lags	2
6	refit	True
7	Metric	700
8	initial_train_size	700
9	fixed_train_size	True
10	return_best	False
11	n_jobs	Auto
12	Verbose	False
13	Metric	MAE

Tabel 3.9 dibawah ini menunjukkan hasil pencarian teratas dengan nilai error terkecil. Berdasarkan hal tersebut, *hyperparameter* algoritma XGBoost adalah *Lags* 2, *Learning rate* 0.2, *Max depth* 500 dan *Number of estimators* 200.

Tabel 3. 9 Hyperparameter Tuning XGBoost

No	***Lags***	***Learning Rate***	***Max Depth***	***Number of estimators***	***MAE***
1	2	0.2	500	200	0.05813
2	2	0.1	150	80	0.06316
3	2	0.1	400	100	0.06624
4	2	0.1	500	150	0.06625

3.5 Pengujian Sistem

Penelitian ini mengevaluasi kinerja model menggunakan persamaan MAE, MAPE, MSE dan RMSE [25].

a. MAE (*Mean Average Error*) Merupakan nilai rata-rata dari kesalahan absolut antara hasil prediksi dan nilai aktual.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|f_i - y_i|$$

b. MAPE (*Mean Average Persentase Error*) dapat dihitung dengan cara mengambil kesalahan absolut pada setiap periode, membaginya dengan nilai observasi nyata untuk periode tersebut, kemudian merata-ratakan kesalahan persentase absolut tersebut.

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{f_i - y_i}{y_i}\right|$$

c. MSE (*Mean Square Error*) adalah Merupakan metode evaluasi untuk prediksi di mana setiap kesalahan atau residu dikuadratkan, kemudian dijumlahkan, dan dibagi dengan jumlah observasi.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(f_i - y_i)^2$$

d. RMSE (*Root Mean Square Error*) Merupakan perbedaan antara nilai yang diprediksi dengan nilai aktual.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(f_i - y_i)^2}$$

Dimana *n* adalah jumlah data; f_i adalah nilai prediksi model dan y_i adalah nilai sebenarnya fitur *close price.*

3.6 Waktu dan Lokasi Penelitian

Penelitian ini dilakukan sealam 6 Bulan terhitung sejak bulan Agustus 2023-Januari 2024. Adapun terkait lokasi penelitian dilaksanakan di Lab AIMP, Departemen Teknik Informatika, Universitas Hasanuddin.

BAB IV HASIL DAN PEMBAHASAN

4.1Pengembangan Model

Dalam proses pengembangan model prediksi harga saham menggunakan analisis teknikal dan skor sentiment ini, kami menggunakan tiga model utama yaitu BERT, BERT LSTM dan BERT XGBoost: BERT untuk skor sentiment, BERT LSTM dan BERT XGBoost untuk melakukan prediksi berdasarkan analisis teknikal dan skor sentiment dari BERT dan dikembangkan berdasarkan prinsip kerja *stacking* ansambel learning.

a. BERT

Langkah pertama adalah memilih model BERT (*Bidirectional Encoder Representation from Transformers*) yang digunakan. Kami menggunakan *Indobert-base-p2* berdasarkan hasil pencaharian *hyperparameter* pada bagian sebelumnya. Proses dimulai dengan mengumpulkan data tweet beserta label sentiment yang sesuai lalu data ini dibagi menjadi dua bagian utama: data latih 70% (untuk melatih model) dan data testing 30%(untuk menguji kinerja model).

Teks-teks dari data latih 70% tersebut di-tokenisasi dan di-encode menggunakan tokenizer dari model *indonbert-base-p2.* Proses tokenisasi mengubah teks menjadi token-token yang dapat dimengerti oleh model, sementera proses encoding menghasilkan representasi vektor dari teks tersebut. Setelah proses tersebut, data dimuat dalam Data Loader. Data Loader ini membagi data menjadi *batch-batch* kecil yang digunakan pada proses pelatihan model. Proses pelatihan dilakukan menggunakan model SentimentClassifier yang dibuat menggunakan arsitektur dari model BERT dan beberapa layer tambahan seperti dropout dan linear untuk output.

Model ini kemudian dilatih menggunakan *loss function Binary Cross Entropy Loss (BCELoss)* dan optimizer AdamW. Proses pelatihan dilakukan dalam 10 epoch sehingga model dapat secara bertahap belajar dari data dan mengoptimalkan parameter-parameter internalnya untuk meningkatkan akurasi dalam mengklasifikasikan sentiment. Adapun rincian parameter-parameter yang kami gunakan dituliskan pada tabel sebagai berikut :

Tabel 4. 1 Konfigurasi *Hyperparameter* Algoritma BERT

No	Parameter	Value
1	*Baseline*	*BERT-Base 12 Transformers*

2	*Model Pretrained*	*Indobenchmark/Indobert-base-p2*
3	*Optimizer*	*AdamW* (*'torch.optim.AdamW'*)
4	*Learning Rate*	0.00001
5	*Dropout*	0.2
6	*Batch Size*	16
7	*Epoch*	10
8	*Loss Function*	*Binary Cross Entropy Loss*
9	*Activation Function*	*Sigmoid*

Parameter diatas disesuaikan dengan *model pretrained* dan tujuan model dikembangkan sehingga jika digunakan pada *model pretrained* dan tujuan yang lain akurasi model mungkin saja berubah atau tidak sama.

b. BERT LSTM

Model BERT LSTM adalah model LSTM yang menggunakan data teknikal dan data skor sentiment dari BERT. Selain itu, terdapat juga model LSTM yang hanya menggunakan data teknikal. Namun pada dasarnya model yang digunakan pada kedua model tersebut adalah sama.

Langkah awal adalah menggabungkan data teknikal dan skor sentiment dari BERT untuk melatih model BERT LSTM. Data skor sentiment dimulai dari tanggal 2020-07-22 hingga 2022-12-30 kemudian digabungkan bersama data teknikal dengan jarak waktu yang sama. Dataset hasil gabungan memiliki fitur yaitu *Date, Open, High, Low, Close, Adj Close, Volume, SkorSentiment, RSI, MA_5, MA_10, MA_20, S_Oscilator.* Selanjutnya data di *preprocessing* dan di normalisasi dan dilakukan pembagian data menjadi set train 80% dan set test 20% untuk melatih dan menguji model.

Arsitektur model LSTM (*Long Short-Term Memory*) yang digunakan untuk analisis teknikal terdiri dari beberapa komponen penting. Pertama, kami mendesain model dengan 3 layer LSTM. Layer pertama dan kedua terdiri dari 15 unit neuron dan layer ketiga terdiri dari dense menggunakan *sigmoid activation* untuk menghasilkan output yang dapat diinterpretasikan dan digunakan dalam proses prediksi. Selama proses pelatihan model menggunakan data train, kami mengoptimalkan beberapa parameter sehingga hasil prediksi lebih baik seperti jumlah neuron dalam setiap layer LSTM, *learning rate*,

penggunaan *adam optimizer*, jumlah *epoch* dan *batch size*. Rincian parameter yang kami gunakan dituliskan pada tabel berikut.

Tabel 4. 2 Konfigurasi Hyperparameter algoritma LSTM dan BERT LSTM

Model	Jumlah Layer	Number of Neurons	Learning rate	Epoch	Batch size	*Optimizer*	*Function Activation*
LSTM Sequential	3	15	0.001	20	32	Adam Optimizer	*Sigmoid*

Setelah proses pelatihan selesai, kami melakukan proses testing menggunakan data testing untuk mengukur kinerja model pada data yang belum pernah dilihat sebelumnya. Proses ini membantu Kami memastikan model LSTM tidak hanya mempelajari data training dengan baik tetapi juga dapat menggeneralisasi dan melakukan prediksi pada data yang belum pernah dilihat sebelumnya.

c. BERT XGBoost

Model BERT XGBoost adalah model XGBoost yang menggunakan data teknikal dan skor sentiment dari BERT. Dataset yang digunakan sama dengan dataset yang digunakan pada model BERT LSTM sebelumnya. Dalam proses pengembangan model prediksi XGBoost Regressor, langkah pertama yang dilakukan adalah pencaharian *hyperparameter* seperti yang telah dijelaskan pada bagian sebelumnya. Selanjutnya parameter terbaik digunakan untuk menginisialisasi model XGBoost Regressor. Model ini akan digunakan untuk memprediksi nilai kolom 'Close' dalam data time series, dengan mempertimbangkan juga beberapa variabel *eksogen* lainnya seperti harga tertinggi ('High'), harga terendah ('Low'), harga pembukaan ('Open'), harga penutupan terkini ('Adj Close'), volume perdagangan ('Volume'), serta indikator teknikal seperti RSI, Moving Average (MA), dan skor sentiment.

Pada model XGBoost Regressor, Kami mengatur parameter ‘Booster’ menjadi ‘dart’. Booster ‘dart’ adalah teknik dropouts yang memungkinkan model untuk belajar dari variasi data yang lebih besar dan mengurangi overfitting. Selanjutnya, Kami membuat forecaster menggunakan Forecaster AutoregDirect dari library skforecast. Forecaster digunakan untuk membuat model *timeseries* dengan pendekatan regresi

menggunakan model XGBoost yang telah disiapkan sebelumnya. Saat membuat forecaster, Kami mengatur parameter-parameter seperti ‘lags’ (lagged values) dan ‘steps’.

Proses training model dilakukan dengan memasukkan data training, yaitu kolom Close dari *timeseries* data serta variabel eksogen lainnya ke dalam forecaster. Hasilnya adalah model *forecaster* yang telah dilatih dan siap digunakan untuk melakukan prediksi terhadap data baru atau data test. Rincian parameter yang kami gunakan pada XGBoost dirincikan pada tabel berikut:

Tabel 4. 3 Konfigurasi hyperparameter BERT XGBoost

No	Parameter	Value
1	Regressor	XGBoost Regressor
	Lags	2
2	max_depth	200
3	n_estimators	500
4	Learning rate	0.2
5	Booster	Dart
6	Steps	179 (Jumlah data tes)
7	Transformer_y	None
8	n_jobs	auto

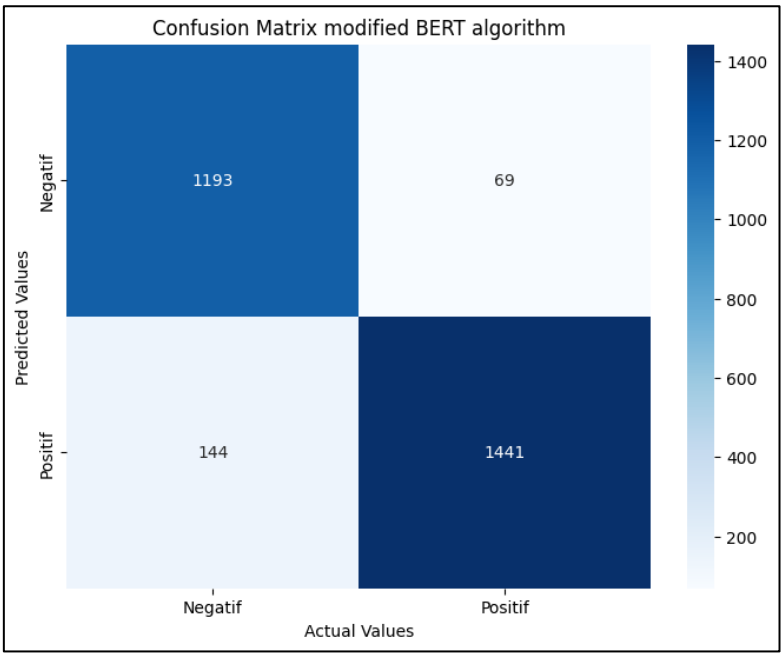
4.2 Evaluasi Model

Pada bagian ini akan dilakukan analisis kinerja model dan dikelompokkan berdasarkan dari jenis data yang diolah masing-masing model yaitu analisis sentiment menggunakan algoritma BERT dan analisis teknikal menggunakan BERT-LSTM dan BERT-XGBoost.

A. BERT

Analisis sentiment menggunakan BERT modifikasi pada penelitian ini menerapkan klasifikasi biner atau klasifikasi 2 kelas yaitu sentiment dengan label 0 = negatif dan label 1 = positif. Alasan memilih klasifikasi biner karena diperlukannya nilai tegas pada data tweet dan alasan teknis lainnya. Dengan pendekatan ini, model akan memprediksi sentiment setiap tweet sebagai negatif atau positif, memudahkan interpretasi dan pengambilan keputusan saat digunakan sebagai data pada model berikutnya.

Model BERT modifikasi yang dikembangkan dievaluasi menggunakan *confusion matrix* sebelum outputnya diubah menjadi skor sentiment. *Confusion Matrix* adalah indikator untuk mengukur performa pada masalah klasifikasi machine learning di mana hasil keluaran dapat berupa dua kelas atau lebih. *Confusion Matrix* berbentuk tabel dengan 4 kombinasi berbeda dari nilai prediksi dan nilai aktual. Ada empat istilah yang mewakili hasil proses klasifikasi pada confusion matrix, yaitu True Positive, True Negative, False Positive, dan False Negative. Adapun hasil evaluasi *confusion matrix* model BERT modifikasi yang dikembangkan sebagai berikut :



Gambar 4. 1 Confusion Matrix BERT Modifikasi

Berdasarkan gambar diatas, jumlah tweet sentiment positif dan negatif pada dataset hampir seimbang, keseimbangan dari dataset sangat berpengaruh terhadap hasil prediksi model BERT modifikasi. Selain itu, dapat dilihat dari *Confusion Matrix* diatas, dari 1510 tweet sentiment positif, model memprediksi ada 69 tweet sentiment negatif (FN) dan dari 1337 tweet sentiment negatif, model memprediksi ada 144 tweet sentiment positif (FP). Prediksi yang benar terletak pada tabel diagonal (berwarna biru). Selanjutnya, *confusion matrix* juga dapat memberikan nilai akurasi, presisi dan recall. Akurasi menggambarkan seberapa baik dan akurat model dalam mengklasifikasikan keseluruhan kelas, presisi mengukur seberapa tepat dan akurat model dalam mengklasifikasikan kelas positif sedangkan recall seberapa banyak kelas positif yang

dapat diprediksi dengan benar oleh model yang dikembangkan. Adapun nilai skor akurasi, presisi dan *recall* untuk BERT modifikasi yang diusulkan sebagai berikut.

Tabel 4. 4 Hasil Evaluasi BERT Modifikasi

Algorithm	**Baseline**	**Accuracy** $\frac{TP+TN}{TP+TN+FP+FN}$	**Precision** $\frac{TP}{TP+FP}$	**Recall** $\frac{TP}{TP+FN}$
BERT Modifikasi	*Indobenchmark/Indobert-base-p2*	0.94	0.90	0.95

Tabel diatas memperlihatkan hasil pengujian analisis sentiment menggunakan algoritma BERT modifikasi dengan *baseline Indobenchmark/Indobert-base-p2* dimana diperoleh skor akurasi sebesar 94%, presisi sebesar 90% dan recall sebesar 95%. Selanjutnya model dimodifikasi pada lapisan *feed forward layer* menggunakan *sigmoid activation* sehingga output menjadi nilai antara 0 dan 1, yang bisa diinterpretasikan sebagai probabilitas sentiment positif. Adapun skor yang diperoleh dapat diinterpretasikan sesuai tabel dibawah ini.

Tabel 4. 5 Interpretasi skor sentiment

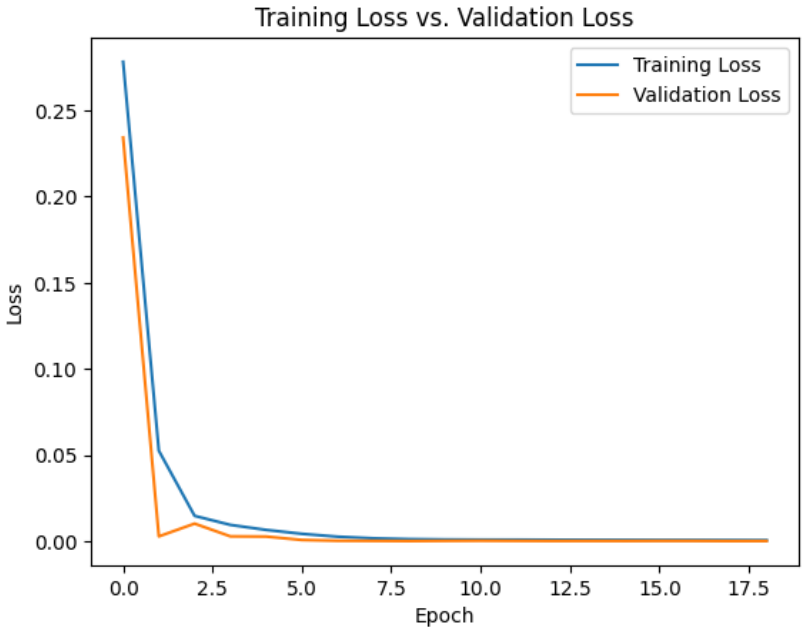
Skor	**Keterangan**
0.0 – 0.2	Sentiment negatif atau sangat negatif
0.3 – 0.5	Sentiment netral atau tidak pasti
0.6 – 0.8	Sentiment positif atau sangat positif
0.9 – 1.0	Sentiment sangat positif

Masing-masing tweet akan memperoleh skor sentiment yang range nya berkisar 0 hingga 1 dan dapat diinterpretasikan seperti tabel diatas. Data skor sentiment kemudian akan digabung dengan analisis teknikal berdasarkan index waktu.

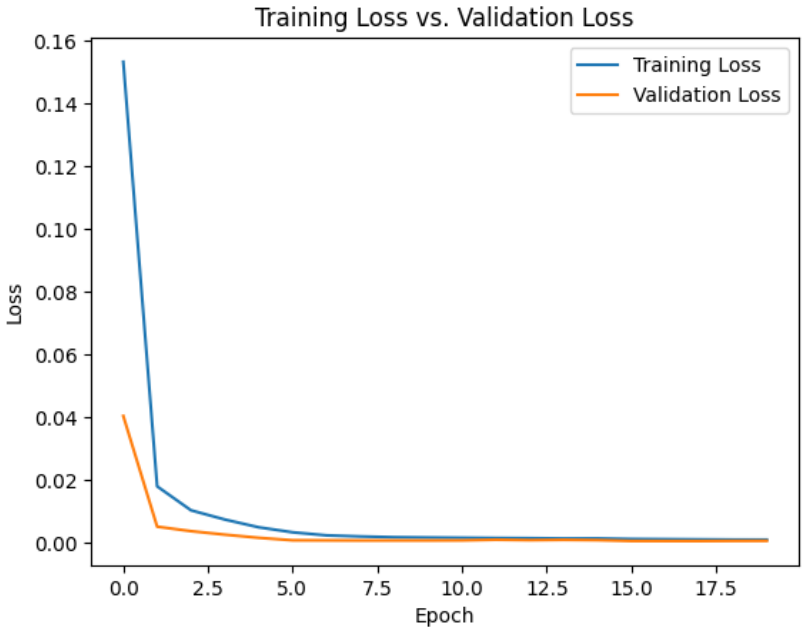
B. BERT LSTM & BERT XGBoost

Analisis teknikal pada penelitian ini adalah tahap terakhir dimana masing-masing variasi algoritma akan dievaluasi yaitu BERT-LSTM, BERT-XGBoost dan LSTM. Model BERT-LSTM dan LSTM dikembangkan dengan konfigurasi model yang sama sesuai hasil pada bagian pencaharian *hyperparameter* yang membedakan hanya pada data fitur. Pada proses *training* model, dilakukan evaluasi *training loss* dan *validation loss*

agar model tidak *overfitting* atau *underfitting*. Hasil *training loss* dan *validation loss* model BERT-LSTM dan LSTM dapat dilihat pada gambar dibawah ini.

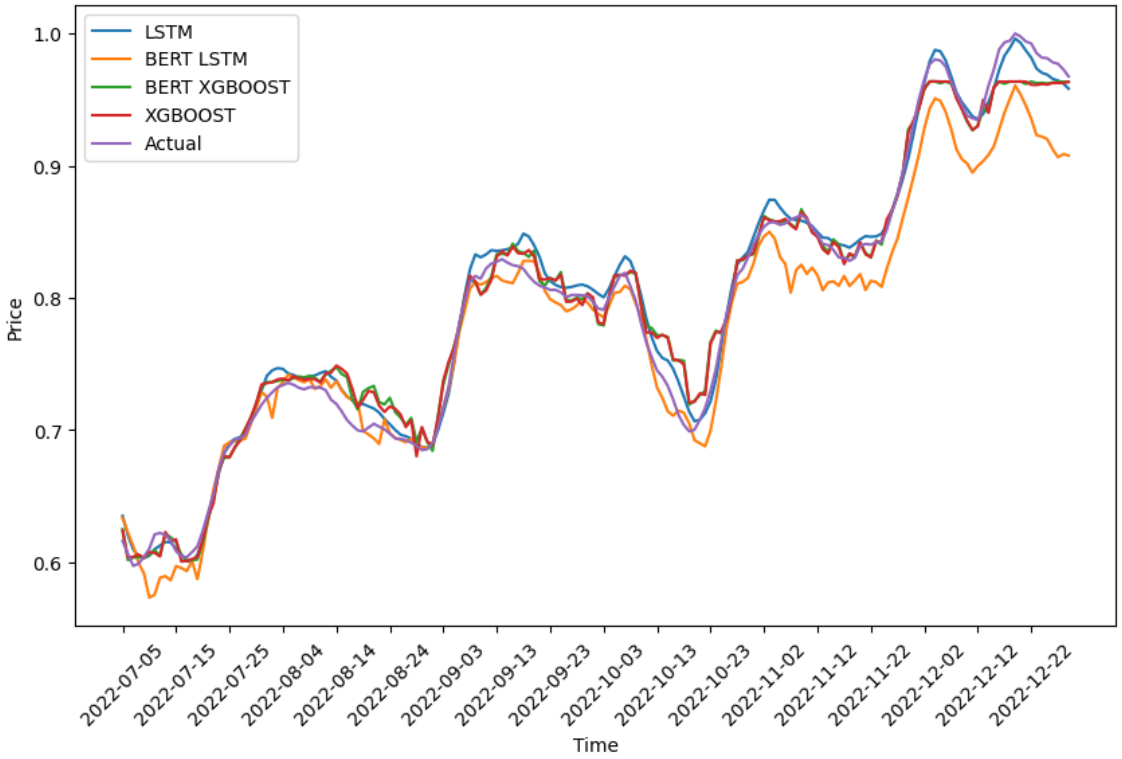


Gambar 4. 2 Training dan Validation loss model LSTM



Gambar 4. 3 Training dan Validation loss model BERT-LSTM

Gambar grafik diatas menunjukkan bahwa kedua model memiliki *training loss* dan *validation loss* yang semakin berkurang seiring bertambahnya epoch pelatihan. Hal ini menunjukkan bahwa model BERT-LSTM dan LSTM tidak overfitting atau model dapat menghafal data training dan mampu beradaptasi pada data baru. Kemudian dilakukan perbandingan kinerja antara model BERT-LSTM, BERT-XGBoost dan LSTM terhadap data aktual. Hasil perbandingan tersebut digambarkan pada gambar dibawah ini.



Gambar 4. 4 Grafik perbandingan prediksi masing-masing model dengan nilai aktual

Berdasarkan gambar diatas, dapat dilihat bahwa keempat model dapat memprediksi dengan baik dan hampir mendekati data aktual. Hasil evaluasi dapat dilihat pada tabel dibawah ini.

Tabel 4. 6 Hasil evaluasi masing-masing model

Method	*Evaluation Metrics*			
	MAE	*RMSE*	*MSE*	*MAPE(%)*
LSTM	0.008	0.010	0.001	1.13
XGBOOST	0.010	0.014	0.002	1.40
BERT-LSTM	0.018	0.025	0.006	2.24
BERT-XGBoost	0.011	0.014	0.002	1.40

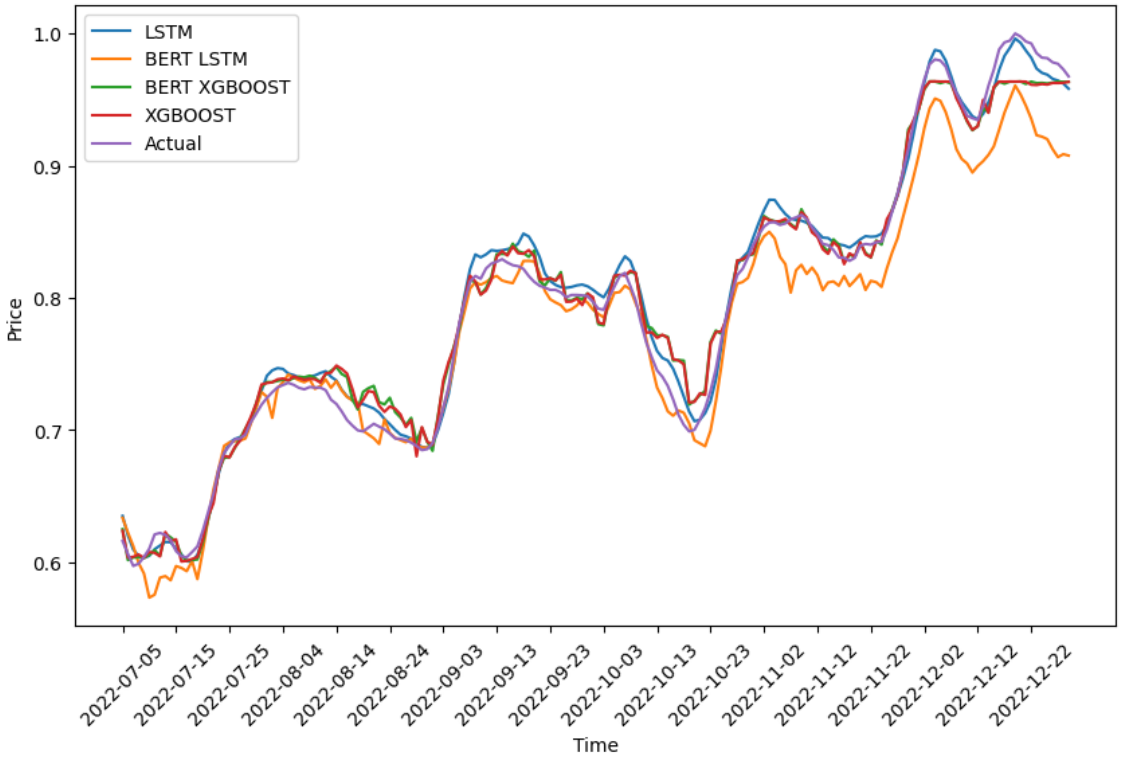
Tabel 4 diatas menjelaskan bahwa model LSTM memperoleh nilai evaluasi yang paling kecil artinya memiliki kesalahan prediksi yang sedikit disusul oleh XGBoost. Hal tersebut karena kedua model ini lebih sederhana dan fokus pada pola harga historis yang relatif stabil dan konsisten yang mencerminkan aktivitas pasar agregat tanpa gangguan dari noise yang sering ada dalam data sentiment. Sebaliknya model BERT-LSTM dan BERT-XGBoost lebih rentan terhadap noise, *temporal misalignment* dan kompleksitas yang memungkinkan menyebabkan *overfitting.* Selain itu, dapat dilihat bahwa model yang menggunakan XGBoost memiliki hasil evaluasi yang lebih baik dibandingkan LSTM dengan nilai MAE, RMSE, MSE dan MAPE berturut-turut sebesar 0.011, 0.014, 0.002 dan 1.40% sehingga disarankan untuk lebih mengeksplorasi dan menggunakan XGBoost dalam penelitian harga saham di masa depan. Model XGBoost terbukti efektif dalam menangani data non-linear dan memiliki kemampuan untuk menangkap pola yang lebih kompleks dalam data finansial seperti harga saham jika dibandingkan LSTM. XGBoost memberikan prediksi yang lebih akurat dan stabil sehingga dapat menjadi pilihan yang lebih unggul dalam analisis prediksi harga saham.

C. Analisis Hubungan antara Skor Sentiment dan Pergerakan Harga Saham

Pada bagian ini dilakukan analisis data antara skor sentiment dan data harga saham. Hal ini bertujuan untuk mengetahui apakah skor sentiment mempengaruhi pergerakan harga saham. Data tabel 4.7 merupakan data dari rata-rata skor sentiment tiap bulannya yang diperoleh dari data skor sentiment harian.

Tabel 4. 7 Skor sentiment Bulanan

No	Tanggal	Skor Sentiment Bulanan
1	31/07/2020	0,552
2	31/08/2020	0,605
3	30/09/2020	0,538
4	31/10/2020	0,628
5	30/11/2020	0,649
6	31/12/2020	0,564
7	31/01/2021	0,587
8	28/02/2021	0,704
9	31/03/2021	0,711
10	30/04/2021	0,567
11	31/05/2021	0,600
12	30/06/2021	0,645
13	31/07/2021	0,531
14	31/08/2021	0,690
15	30/09/2021	0,492
16	31/10/2021	0,706
17	30/11/2021	0,844
18	31/12/2021	0,471
19	31/01/2022	0,544
20	28/02/2022	0,687
21	31/03/2022	0,674
22	30/04/2022	0,742
23	31/05/2022	0,567
24	30/06/2022	0,606
25	31/07/2022	0,628
26	31/08/2022	0,829
27	30/09/2022	0,813
28	31/10/2022	0,639
29	30/11/2022	0,617
30	31/12/2022	0,825



Gambar 4. 4 Grafik perbandingan prediksi masing-masing model dengan nilai aktual

Jika memperhatikan Tabel 4.7 dan Gambar 4.4, terlihat adanya pergerakan harga saham yang signifikan, khususnya peningkatan atau bullish yang terjadi pada rentang waktu Agustus hingga September 2022 dengan kenaikan berkisar 10%. Selama periode tersebut, skor sentiment pasar berkisar di angka 0.8, mengindikasikan sentiment pasar yang positif. Sebaliknya, pada bulan Oktober terjadi penurunan atau bearish berkisar 12%, di mana skor sentiment menurun menjadi sekitar 0.6, yang menunjukkan adanya sentiment pasar negatif. Setelah itu, terdapat peningkatan harga saham kembali pada awal bulan Desember yang diiringi dengan sentiment pasar positif. Hal ini menunjukkan adanya korelasi antara sentiment pasar dan pergerakan harga saham, di mana sentiment positif cenderung diikuti oleh kenaikan harga, sementara sentiment negatif diiringi oleh penurunan harga. Pola ini memberikan indikasi awal bahwa sentiment pasar dapat berfungsi sebagai indikator potensial dalam memprediksi arah pergerakan harga saham. Namun, diperlukan analisis lebih mendalam dan komprehensif untuk memastikan apakah pola ini konsisten pada periode waktu lainnya dan untuk menilai keandalan sentiment pasar sebagai alat prediksi yang dapat diandalkan dalam berbagai kondisi pasar.